DEPARTAMENTO DE
INGENIERÍA QUÍMICA
Y BIOPROCESOS

DIPLOMADO DE GESTIÓN DE CALIDAD DEL AIRE Y CONTROL DE CONTAMINACIÓN ATMOSFÉRICA

MODELOS DE PRONÓSTICO



OBJETIVO

- Entregar a los participantes fundamentos teóricos y prácticos para desarrollar modelos de machine learning aplicados a la calidad del aire, utilizando R y metodologías reproducibles de ciencia de datos.

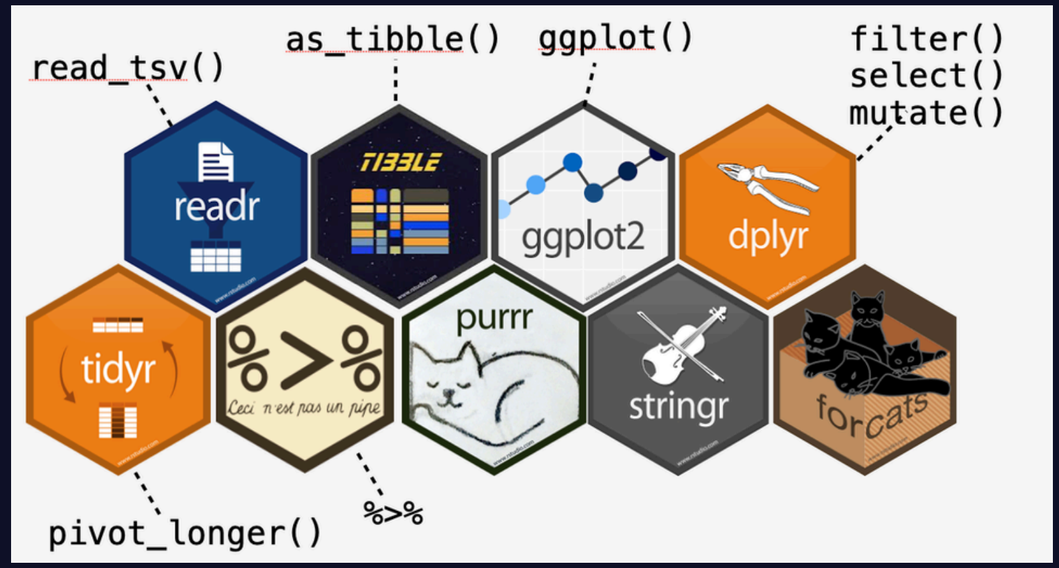
CONTENIDOS

- Fundamentos de R para ciencia de Datos.
- Desarrollo de un Proyecto de Data Science en Calidad del Aire.
- Introducción al Machine Learning aplicado a Calidad del Aire.
- Random Forest y Evaluación de Modelos.



FUNDAMENTOS DE R PARA CIENCIA DE DATOS AMBIENTAL

- Introducción a R y RStudio.
- Estructura de un proyecto reproducible.
- Introducción a tidyverse.
  - Lectura de datos ambientales.
  - Manipulación básica (select, filter, mutate, group_by).
- Uso conceptual de renv para control de dependencias.
- Introducción a la creación de funciones simples.
- Ejercicio práctico con datos de estaciones de calidad del aire.



FUNDAMENTOS DE R PARA CIENCIA DE DATOS AMBIENTAL

Introducción a R y RStudio

- R es un lenguaje de programación y un entorno de software libre para computación estadística y gráficos. Es ampliamente utilizado por estadísticos y científicos de datos para analizar datos, desarrollar software estadístico y crear visualizaciones de datos.
- RStudio es un entorno de desarrollo integrado (IDE) gratuito y de código abierto para R. Proporciona una interfaz fácil de usar con un editor de código, herramientas de depuración, un navegador de entorno y un sistema de gestión de paquetes, lo que facilita el trabajo con R.
- Una alternativa en línea a RStudio de Posit (la empresa detrás de RStudio) es Posit Cloud (anteriormente RStudio Cloud). Posit Cloud es una plataforma basada en la web que te permite usar R y RStudio en tu navegador, sin necesidad de instalar nada en tu computadora local. Es ideal para aprender, enseñar, colaborar en proyectos y ejecutar análisis R desde cualquier lugar con conexión a internet. Ofrece un entorno RStudio completo con la ventaja de que todo se ejecuta en la nube, facilitando la gestión de dependencias y la colaboración.

DESARROLLO DE UN PROYECTO DE DATA SCIENCE EN CALIDAD DEL AIRE

Limpieza de Datos

La Limpieza de datos (Data Cleaning) es el proceso para encontrar y corregir datos inexactos, atípicos o vacíos en un conjunto particular. El objetivo es poder identificar, corregir o eliminar las inconsistencias que pueden crear incoherencias en los resultados.

Métodos

- Detección de Outliers.
  - Métodos estadísticos univariados (IQR, Z-score).
  - Métodos estadísticos multivariados (LOF).
  - Outliers reales vs. Eventos ambientales.

DESARROLLO DE UN PROYECTO DE DATA SCIENCE EN CALIDAD DEL AIRE

Métodos estadísticos univariados

IQR

Un valor se considera atípico si está fuera del rango:

$$[Q1 - 1{,}5 \times RIC,\ Q3 + 1{,}5 \times RIC]$$

donde Q1 es el primer cuartil, Q3 el tercer cuartil y RIC = Q3 − Q1. Método no paramétrico (ya que no depende de supuestos de distribución)

Z-Score

Mide cuántas desviaciones estándar se aleja un dato de la media.

$$z = \frac{x - \mu}{\sigma}$$

Si $|z| > 2$, el dato es atípico.

DEPARTAMENTO DE
INGENIERÍA QUÍMICA
Y BIOPROCESOS

DIPLOMADO DE GESTIÓN DE CALIDAD DEL AIRE Y CONTROL DE CONTAMINACIÓN ATMOSFÉRICA

MODELOS DE PRONÓSTICO



DESARROLLO DE UN PROYECTO DE DATA SCIENCE EN CALIDAD DEL AIRE

Tratamiento de Datos

- Normalización y Estandarización.
- Generación de Variables temporales (hora, día, estación).
- Transformación de viento (componente U y V).

DEPARTAMENTO DE
INGENIERÍA QUÍMICA
Y BIOPROCESOS

DIPLOMADO DE GESTIÓN DE CALIDAD DEL AIRE Y CONTROL DE CONTAMINACIÓN ATMOSFÉRICA

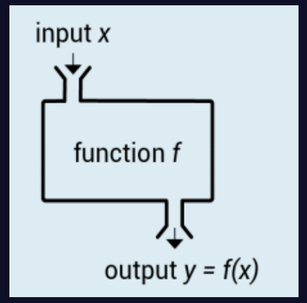
MODELOS DE PRONÓSTICO - PARTE II



INTRODUCCIÓN AL MACHINE LEARNING

¿Qué son los algoritmos supervisados?

En los algoritmos de Aprendizaje Supervisado la data es de la forma donde se denominan inputs o variables de entrada e es el output o variable de salida. El modelo representa la función de mapeo de los inputs a los outputs:



Dependiendo de la naturaleza de la variable respuesta , el modelo es de clasificación (si es categórica) o de regresión (si es numérica). Es importante reconocer la naturaleza de la variable respuesta pues a partir de esta, descartamos los modelos que no serían adecuados para el caso de estudio.

INTRODUCCIÓN AL MACHINE LEARNING

Arboles de Decisión

Corresponde a una técnica de Machine Learning de tipo Supervisado. Al final del entrenamiento, se obtienen secuencias de preguntas de los datos que llevan a un resultado o predicción. Un plus que tiene esta técnica es que es posible visualizar las secuencias de preguntas en forma de árbol, siendo fácil de explicar y comprender para la audiencia.
Los árboles de decisión se clasifican en:

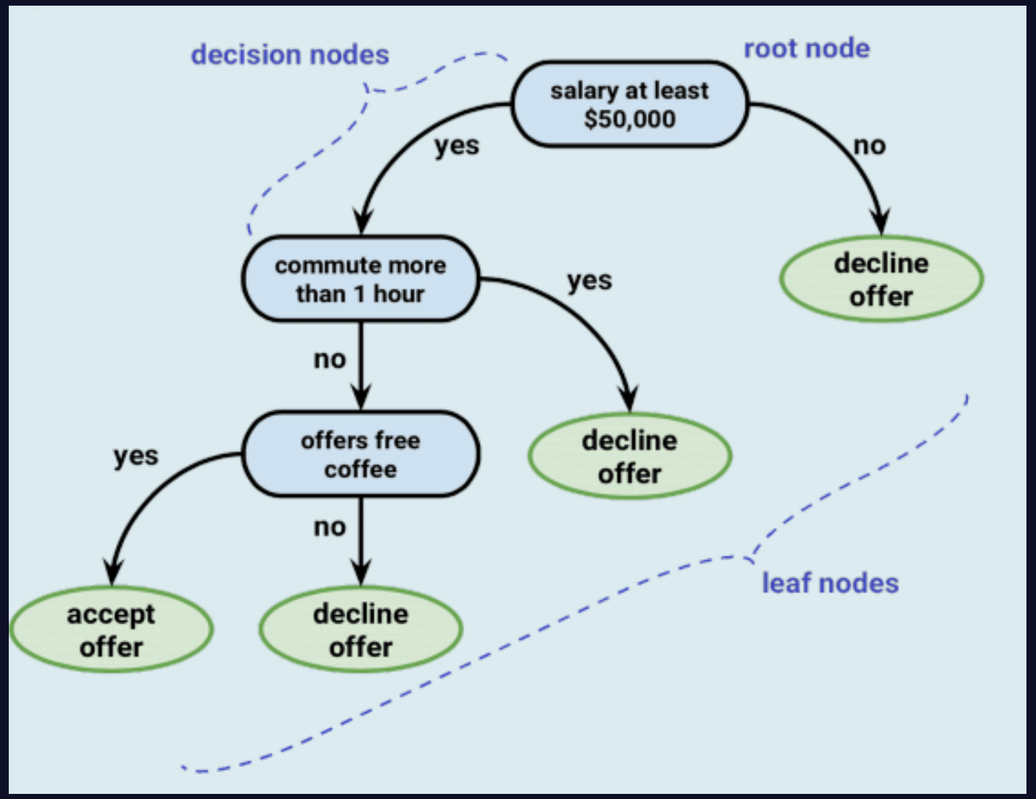
- **Árbol de Regresión: Cuando la variable output es numérica. Ejemplo: Determinar las secuencias de preguntas adecuadas de modo de predecir el salario de un colaborador.**
- **Árbol de Clasificación: Cuando la variable output es categórica. Ejemplo: Determinar las secuencias de preguntas adecuadas de modo de predecir el fallo o no fallo de un producto.**

INTRODUCCIÓN AL MACHINE LEARNING

Ejemplo de Arboles de Clasificación

Podemos observar las siguientes partes del árbol:

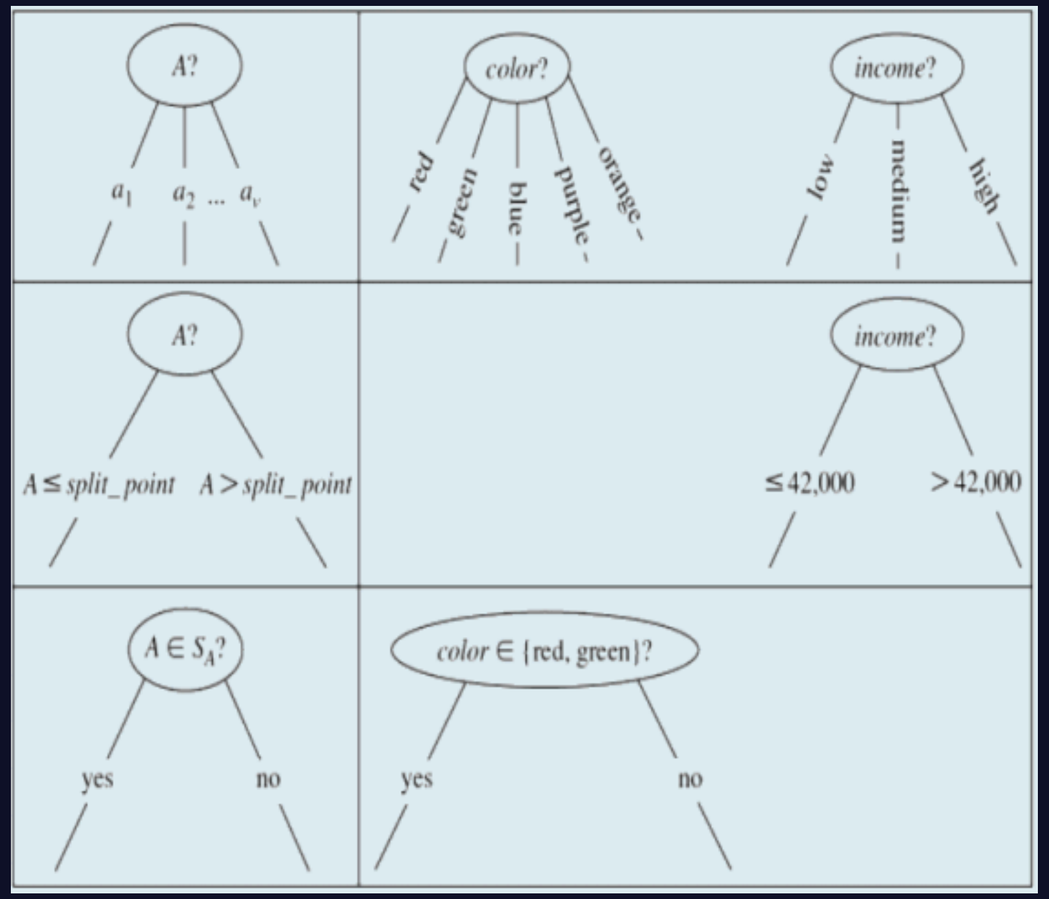
- **Cada nodo de decisión (decision node) representa una pregunta sobre un atributo. El nodo raíz (root node) corresponde a la primera pregunta.**
- **Cada rama representa una posible respuesta a las preguntas.**
- **Cada hoja o nodo terminal (leaf node) representa la clase o predicción al seguir ese camino.**



ARBOLES DE CLASIFICACIÓN

¿Cómo se obtienen las preguntas?

1. **Si todas las observaciones pertenecen a la misma clase o categoría, se crea un nodo terminal con dicha categoría.**
2. **Si no, se recurre a algún método para determinar la primera pregunta o criterio de separación, la idea es obtener particiones puras (que los grupos estén en la menor medida posible mezclados, es decir más homogéneos).**
3. **Se crea el primer nodo el criterio de separación encontrado, este proceso se itera de forma de añadir ramas y nodos de forma anidada hasta que ocurra alguno de los siguientes casos:**
    a. **Todas las tuplas pertenecen a la misma clase.**
    b. **No hay más atributos para particionar.**
    c. **Ya no hay más datos.**



ARBOLES DE CLASIFICACIÓN

Criterios de Ramificación

Hasta ahora comprendemos el proceso de crecimiento del árbol, pero necesitamos saber cómo discernir entre usar una u otra variable para crear los nodos de decisión.

Algunos métodos o criterios de ramificación que existen son:

- Entropía o Ganancia de información
- Impureza Gini

Entropía o Ganancia de información

Este método trata de representar cuánta información he ganado particionando por cierto atributo y se relaciona con el grado de impureza del nodo.

- Si el resultado al separar por un atributo es obvio (gran impureza del nodo 50%-50%), no he ganado información, por lo tanto, no vale mucho la pena utilizar ese atributo.
- Si el resultado al separar por un atributo no era tan obvio (baja impureza 90%-10%), he ganado mucha información, porque no era algo obvio o esperable.

ARBOLES DE CLASIFICACIÓN

Entropía o Ganancia de información

La información esperada necesaria o entropía, para clasificar una tupla en alguna de las C_1,...,C_m clases es:

$$\text{Info}(D) = -\sum_{i=1}^{m} p_i log_2(p_i)$$

Donde consiste en la probabilidad de pertenecer a la clase C_i. Para saber cuánto es el grado de entropía luego de la partición sugerida por el atributo A, calculamos:

$$\text{Info}_A(D) = \sum_{j=1}^{v} q_j \cdot \text{Info}(D_j)$$

Donde q_j corresponde a la probabilidad de pertenecer a la categoría j del atributo A.

ARBOLES DE CLASIFICACIÓN

Ejemplo: ¿La cancha se encuentra habilitada para jugar?

La siguiente tabla contiene datos de distintos días donde la variable Tenis indica si la cancha estaba o no habilitada para jugar. A modo de ejemplo calcularemos la entropía para el atributo Pronóstico.

Las probabilidades globales de pertenecer a cada clase C_i son:

$$p_{si} = \frac{8}{14} \text{ y } p_{no} = \frac{6}{14}$$

La entropía global Info(D) es:

$$-\frac{8}{14}log_2(\frac{8}{14}) - \frac{6}{14}log_2(\frac{6}{14}) = 0.985$$

Día	Temperatura	Pronóstico	Humedad	Viento	Tenis
5-Jul	caluroso	soleado	alta	no	no
6-Jul	caluroso	soleado	alta	si	no
7-Jul	caluroso	nublado	alta	no	si
9-Jul	frio	lluvia	normal	no	si
10-Jul	frio	nublado	normal	si	si
12-Jul	templado	soleado	alta	no	no
14-Jul	frio	soleado	normal	no	si
15-Jul	templado	lluvia	normal	no	si
20-Jul	templado	soleado	normal	si	si
21-Jul	templado	nublado	alta	si	no
22-Jul	caluroso	nublado	normal	no	si
23-Jul	templado	lluvia	alta	si	no
26-Jul	frio	lluvia	normal	si	no
30-Jul	templado	lluvia	alta	no	si

ARBOLES DE CLASIFICACIÓN

Ejemplo: ¿La cancha se encuentra habilitada para jugar?

Para calcular la entropía de pronóstico, debemos calcular las probabilidades de cada categoría en pronóstico:

$$q_{soleado} = \frac{5}{14}, q_{nublado} = \frac{4}{14} \text{ y } q_{lluvia} = \frac{5}{14}$$

Y las probabilidades de cada clase en cada categoría del atributo pronóstico son:

$$p_{si,soleado} = \frac{2}{5} \text{ y } p_{no,soleado} = \frac{3}{5}$$
$$p_{si,nublado} = \frac{3}{4} \text{ y } p_{no,nublado} = \frac{1}{4}$$
$$p_{si,lluvia} = \frac{3}{5} \text{ y } p_{no,lluvia} = \frac{2}{5}$$

Y la entropía asociada a la variable pronóstico Info_{pronóstico} (D) es:

$$\frac{5}{14}[-\frac{2}{5}log_2(\frac{2}{5}) - \frac{3}{5}log_2(\frac{3}{5})] + \frac{4}{14}[-\frac{3}{4}log_2(\frac{3}{4}) - \frac{1}{4}log_2(\frac{1}{4})] + \frac{5}{14}[-\frac{3}{5}log_2(\frac{3}{5}) - \frac{2}{5}log_2(\frac{2}{5})] = 0.925$$

Día	Temperatura	Pronóstico	Humedad	Viento	Tenis
5-Jul	caluroso	soleado	alta	no	no
6-Jul	caluroso	soleado	alta	si	no
7-Jul	caluroso	nublado	alta	no	si
9-Jul	frio	lluvia	normal	no	si
10-Jul	frio	nublado	normal	si	si
12-Jul	templado	soleado	alta	no	no
14-Jul	frio	soleado	normal	no	si
15-Jul	templado	lluvia	normal	no	si
20-Jul	templado	soleado	normal	si	si
21-Jul	templado	nublado	alta	si	no
22-Jul	caluroso	nublado	normal	no	si
23-Jul	templado	lluvia	alta	si	no
26-Jul	frio	lluvia	normal	si	no
30-Jul	templado	lluvia	alta	no	si

ARBOLES DE CLASIFICACIÓN

Ejemplo: ¿La cancha se encuentra habilitada para jugar?

Si calculamos la entropía para los atributos Humedad y Viento de manera análoga, obtenemos:

Atributo	Entropía
Pronóstico	0.925
Humedad	0.833
Viento	0.936

¿Cuál de estos atributos elegiríamos para el nodo raíz? Según el método de entropía, aquél que tenga la menor entropía o impureza, en este caso sería Humedad (menor impureza mayor ganancia de información), por lo tanto la primera pregunta sería ¿La humedad es alta?

Para seguir con el árbol se calculan las entropías dado que ya está separado por humedad y así sucesivamente hasta llegar a algún criterio de parada.

ARBOLES DE CLASIFICACIÓN

Impureza de Gini

Representa la probabilidad de que una muestra seleccionada al azar de un nodo se clasifique incorrectamente de acuerdo con la distribución de muestras en el nodo.

Al entrenar un árbol de decisión, la mejor división se elige minimizando la impureza de Gini, que se calcula restando las impurezas ponderadas de las ramas de la impureza original.

ARBOLES DE CLASIFICACIÓN

Impureza de Gini

Los datos se dividen según el atributo A, en dos regiones, A_1 y A_2, con n_1 y n_2 elementos, respectivamente. p_{ji} corresponde a la proporción de elementos en A_j con $j = 1, 2$ que pertenecen a la clase i con $i = 1, \ldots, m$.

La impureza de Gini $I(A_j)$ se calcula:

$$= p_{j1}(1 - p_{j1}) + p_{j2}(1 - p_{j2}) + \ldots + p_{jm}(1 - p_{jm})$$

$$= \sum_{i=1}^{m} p_{ji}(1 - p_{ji}) = \sum_{i=1}^{m} (p_{ji} - p_{ji}^2) = \sum_{i=1}^{m} p_{ji} - \sum_{i=1}^{m} p_{ji}^2$$

$$= 1 - \sum_{k=1}^{m} p_{ji}^2$$

Y el índice de Gini se calcula:

$$\text{Gini}(A) = q_1 I(A_1) + q_2 I(A_2)$$

Donde q_j corresponde a la probabilidad de pertenecer a la categoría j del atributo A.

ARBOLES DE CLASIFICACIÓN

Ejemplo: Retorno de préstamos

En el siguiente ejemplo, se tienen variables de distintos préstamos e interesa predecir la variable Return.

Para calcular el índice de Gini para el atributo Past Trend, debemos calcular las probabilidades de cada categoría del atributo:

$$q_{Positive} = \frac{6}{10} \text{ y } q_{Negative} = \frac{4}{10}$$

Y las probabilidades de cada clase en cada categoría del atributo Past Trend son:

$$p_{up,Positive} = \frac{4}{6} \text{ y } p_{down,Positive} = \frac{2}{6}$$
$$p_{up,Negative} = \frac{0}{4} \text{ y } p_{down,Negative} = \frac{4}{4}$$

Past Trend	Open Interest	Trading Volume	Return
Positive	Low	High	Up
Negative	High	Low	Down
Positive	Low	High	Up
Positive	High	High	Up
Negative	Low	High	Down
Positive	Low	Low	Down
Negative	High	High	Down
Negative	Low	High	Down
Positive	Low	Low	Down
Positive	High	High	Up

ARBOLES DE CLASIFICACIÓN

Ejemplo: Retorno de préstamos

Luego, las impurezas se pueden obtener como siguen:

$$I(A_{Positive}) = 1 - ((4/6)^2 + (2/6)^2) = 0.44$$

$$I(A_{Negative}) = 1 - ((0)^2 + (4/4)^2) = 0$$

Y el índice de Gini del atributo Past Trend es:

$$\text{Gini}(PastTrend) = \frac{6}{10} \cdot 0.44 + \frac{4}{10} \cdot 0 = 0.27$$

Past Trend	Open Interest	Trading Volume	Return
Positive	Low	High	Up
Negative	High	Low	Down
Positive	Low	High	Up
Positive	High	High	Up
Negative	Low	High	Down
Positive	Low	Low	Down
Negative	High	High	Down
Negative	Low	High	Down
Positive	Low	Low	Down
Positive	High	High	Up

ARBOLES DE CLASIFICACIÓN

Ejemplo: Retorno de préstamos

Si realizamos el mismo cálculo para los atributos Open Interest y Trading Volume obtenemos:

Atributo	Índice de Gini
Past Trend	0.27
Open Interest	0.47
Trading Volume	0.34

En base al criterio de Gini, se elegiría como nodo raíz el atributo Past Trend. Por lo tanto, la primera pregunta sería ¿Past Trend es Positivo?.

Para seguir con el árbol se calculan los índices de Gini dado que ya está separado por Past Trend y así sucesivamente hasta llegar a algún criterio de parada.

ARBOLES DE CLASIFICACIÓN

Algunas aplicaciones de árboles de decisión

- **Física: detección de partículas**
- **Ingeniería biomédica: identificar dispositivos implantables**
- **Análisis financiero: satisfacción del cliente**
- **Astronomía: clasificación de estrellas**
- **Medicina: diagnóstico**

Entre muchas otras.

DEPARTAMENTO DE
INGENIERÍA QUÍMICA
Y BIOPROCESOS

DIPLOMADO DE GESTIÓN DE CALIDAD DEL AIRE Y CONTROL DE CONTAMINACIÓN ATMOSFÉRICA

MODELOS DE PRONÓSTICO - PARTE II



BAGGING

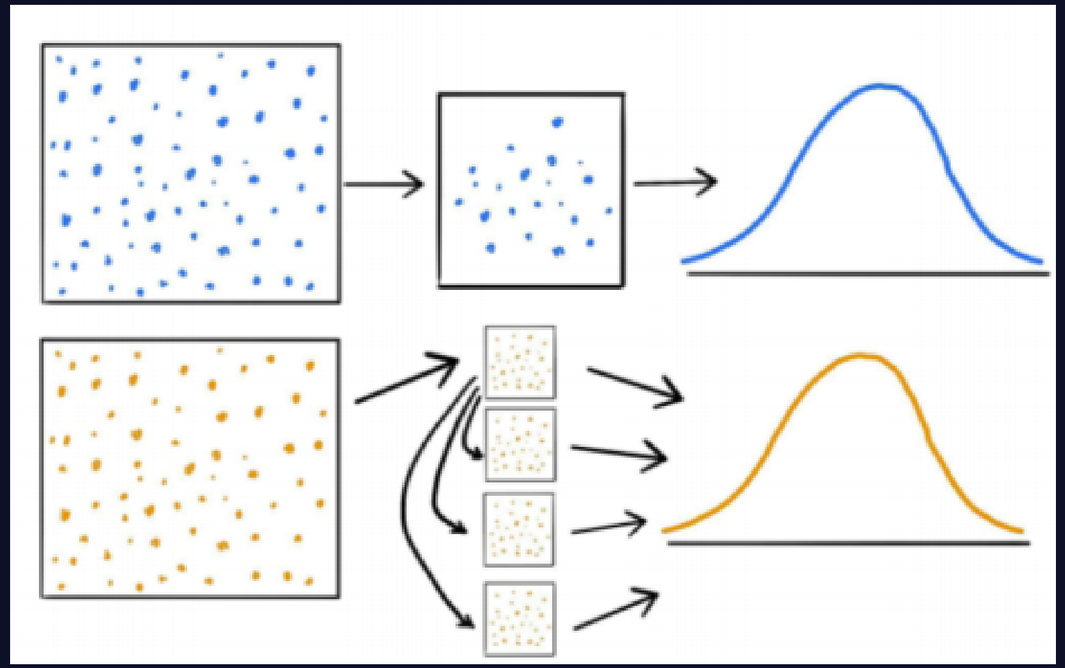
Bootstrap

El Bootstrap es un método de remuestreo que consiste en calcular un estadístico, tomando muestras con reemplazo una cantidad de veces igual al tamaño de la data y replicando el proceso múltiples veces. Las distintas realizaciones del estadístico es lo que se conoce como la muestra Bootstrap y esta simula la distribución del estadístico.

Para una muestra de tamaño n:

- **Muestrear n veces con reemplazo**
- **Calcular T(x), el estadístico objetivo para la muestra tomada en el paso 1.**
- **Repetir los pasos B veces.**

Lo que se obtendrá son B realizaciones del estadístico T(x).



BAGGING

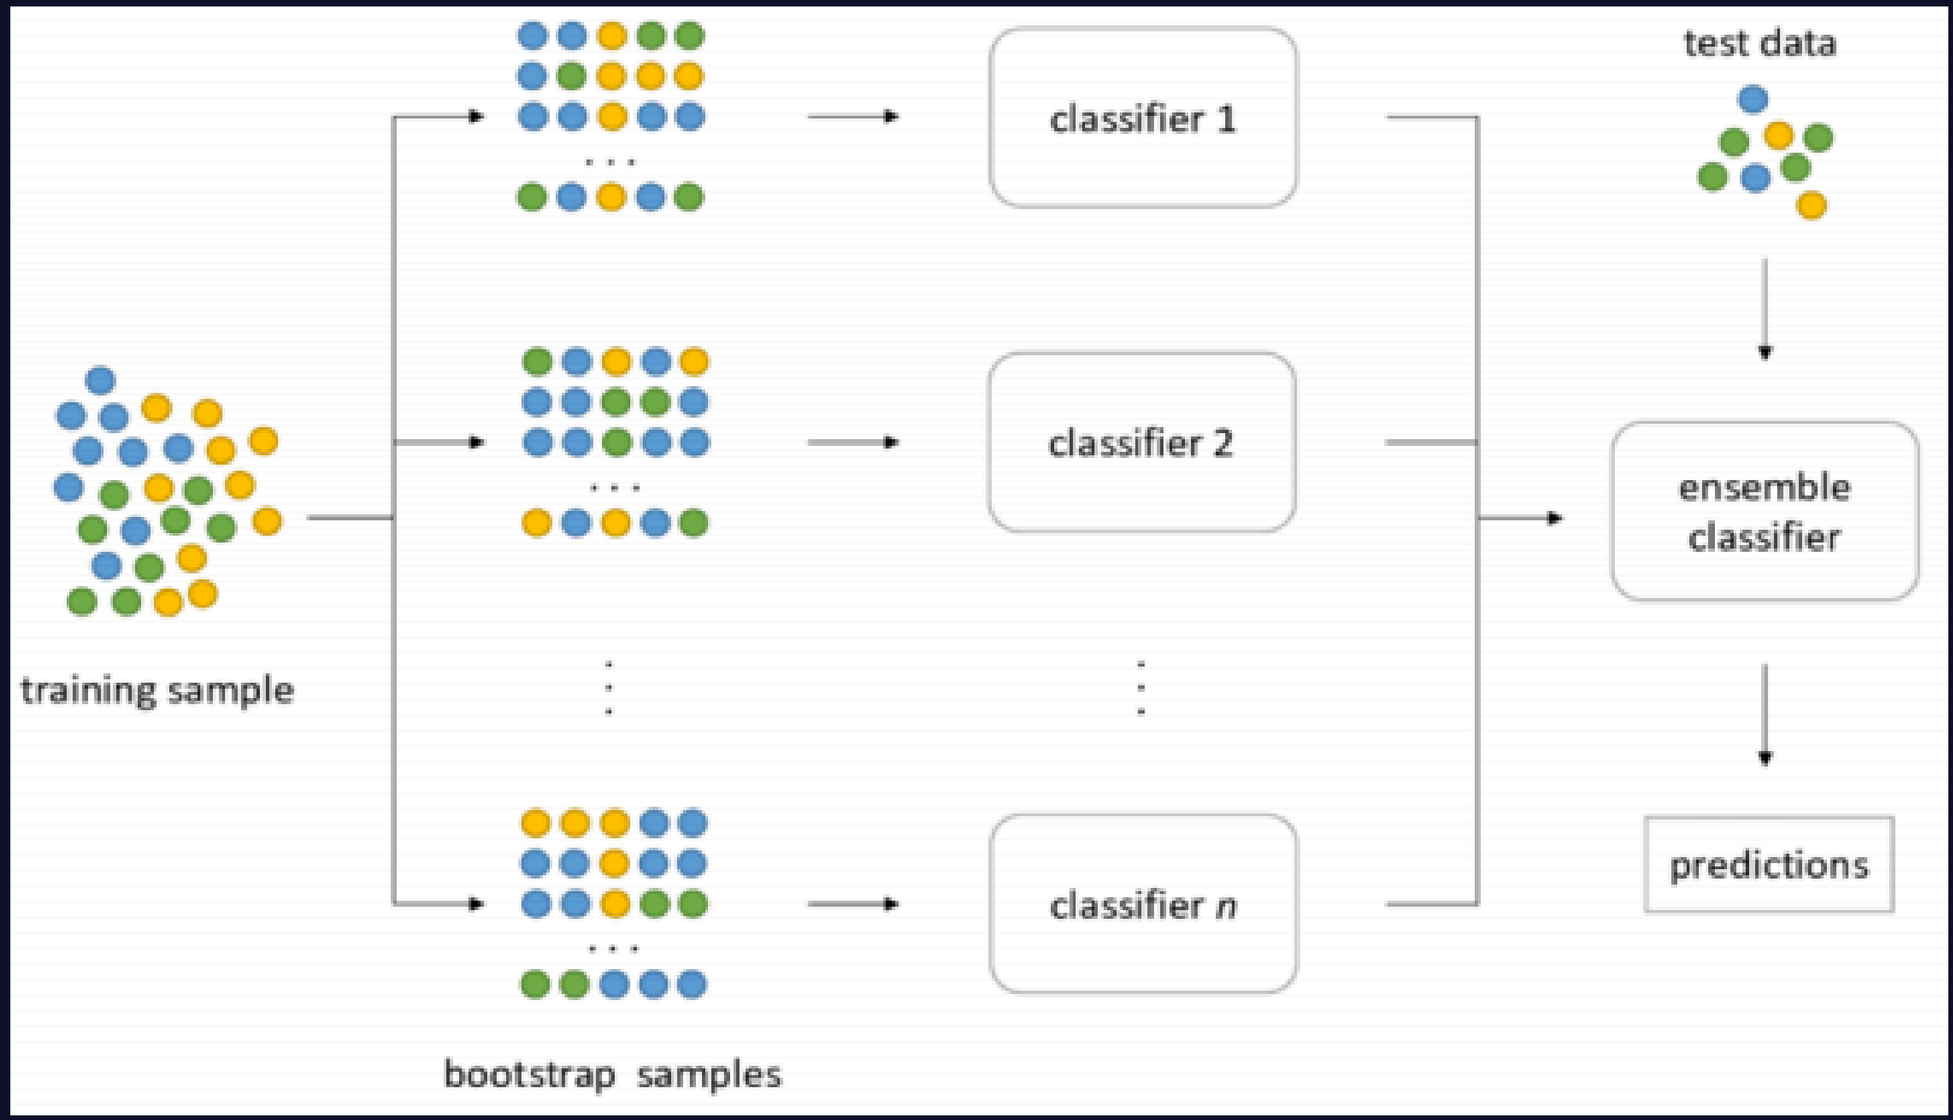
Bootstrap aggregation

Dado que esto se puede aplicar a un estadístico, ¿Que tan alocada es la idea de aplicarla a un modelo supervisado?

Esto es lo que se conoce como método de bagging o bootstrap aggregation, es un método de ensamblaje que ejecuta muchos modelos con remuestreos a los datos, para luego agregar sus predicciones con el fin de obtener una predicción más robusta.

En efecto, se hacen B muestras, se ajusta un modelo a cada una de ellas y luego se les hace competir a los modelos, esto es el paso de agregación. Cuando el modelo es de regresión, esta suele ser el promedio de las predicciones de los modelos, mientras que en un clasificador es la clase mayoritaria.

BAGGING


test data
classifier 1
classifier 2
classifier n
ensemble classifier
predictions
training sample
bootstrap samples

BAGGING

Los árboles de decisión sufren de alta varianza, lo que signi¦ca que, si dividiéramos al azar los datos de entrenamiento en dos grupos y ajustáramos un árbol de decisión a cada mitad, los resultados que obtendríamos podrían ser radicalmente diferentes.

El método de bagging es una técnica que se utiliza para reducir la varianza de un método de aprendizaje estadístico, usado muy frecuentemente con árboles de decisión.

Procedimiento

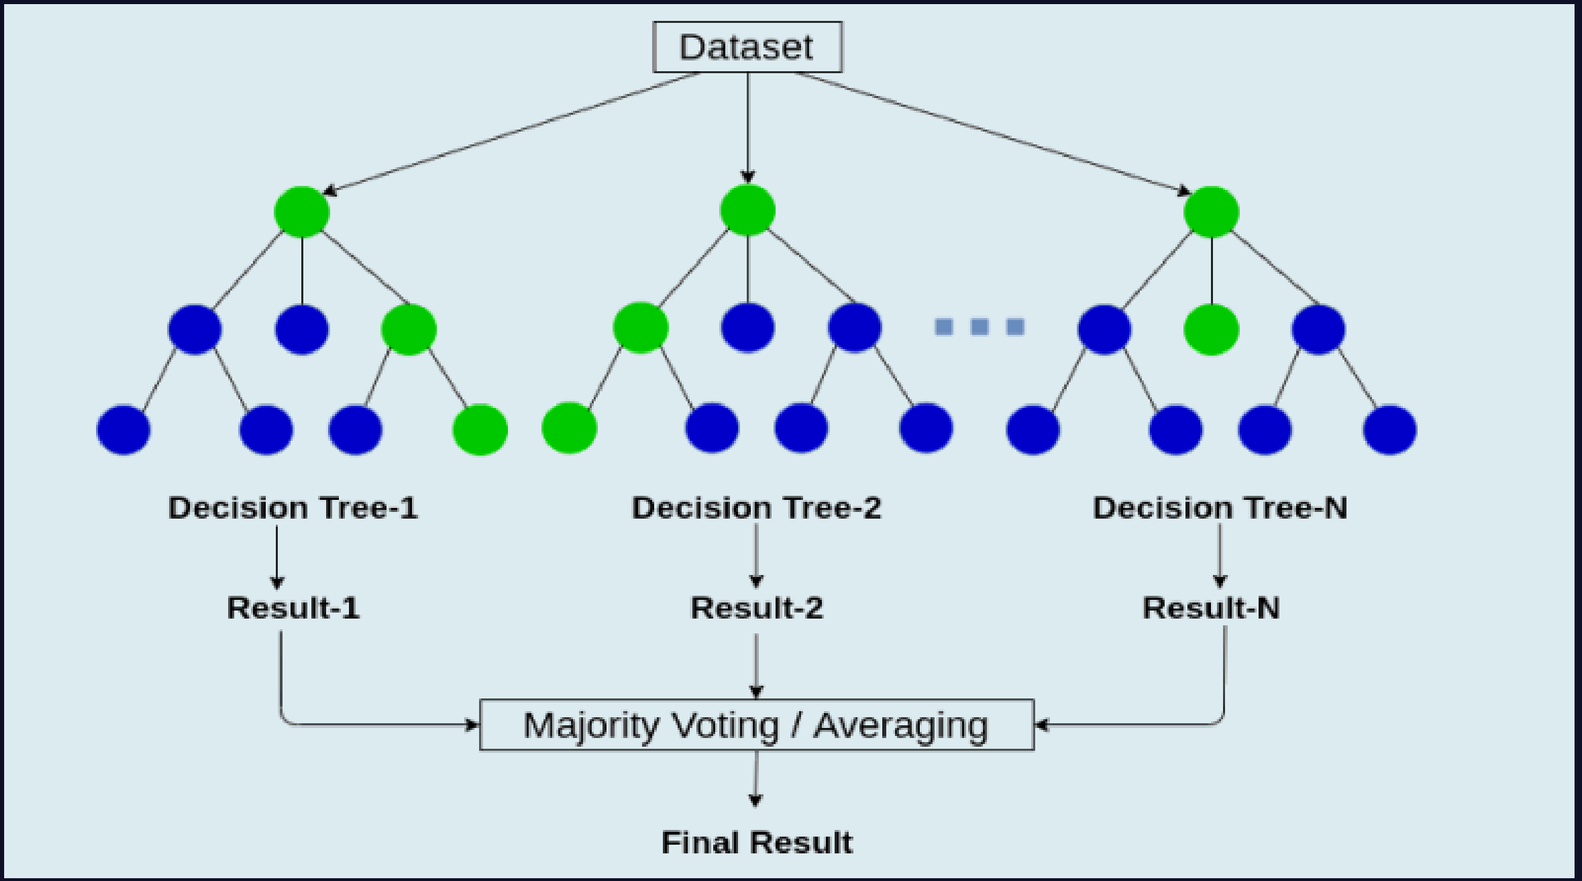
1. **Producir varios conjuntos de entrenamiento.**
2. **Crear para cada conjunto de entrenamiento, un modelo (en este caso, un árbol de decisión).**
3. **Combinar las predicciones de todos estos modelos obtenidos.**

BOSQUE DE ÁRBOLES

Corresponde a una técnica de Machine Learning que se basa en un conjunto de árboles de decisiones seleccionando aleatoriamente submuestras (con reemplazamiento) para elaborar cada árbol.

El punto clave del Bosque de árboles es utilizar una serie de árboles de decisión (diferentes individuos y diferentes variables), con el fin de mejorar la tasa de clasificación correcta. La diferencia con el bagging es que en el bosque de árboles también se toma una muestra de los features, es decir, no se utilizan todas las variables como en el bagging.

BOSQUE DE ÁRBOLES



BOSQUE DE ÁRBOLES - IMPORTANCIA

Si bien es cierto que el proceso de Random Forest consigue mejorar la capacidad predictiva en comparación a los modelos basados en un único árbol, esto tiene un coste asociado, la interpretabilidad del modelo se reduce. Al tratarse de una combinación de múltiples árboles, no es posible obtener una representación gráfica sencilla del modelo y no es inmediato identificar de forma visual qué predictores son más importantes.

Sin embargo, se han desarrollado nuevas estrategias para cuantificar la importancia de los predictores. Dos de estas medidas son:

- **Importancia por permutación: Identifica la influencia que tiene cada predictor sobre una determinada métrica de evaluación del modelo (mse, classification error). Si el predictor permutado estaba contribuyendo al modelo, es de esperar que el modelo aumente su error, ya que se pierde la información que proporcionaba esa variable.**
- **Impureza de nodos: Cuantifica el incremento total en la pureza de los nodos debido a divisiones en las que participa el predictor (promedio de todos los árboles).**

BOSQUE DE ÁRBOLES

Ventajas	Desventajas
Puede manejar miles de variables de entrada y reconocer las significativas	Pérdida de interpretación
Una de las salidas del modelo es el feature importance	Bueno para clasificación, no tanto para regresión
Es posible usarlo en otros casos (clustering y detección de anomalías)	Poco control en lo que hace (caja negra)